

EJERCICIO 1.

Crea un nuevo RDD con 3 particiones a partir del siguiente array de números. Calcula:

```
import org.apache.spark.SparkConf
import org.apache.spark.SparkContext
import org.apache.spark.rdd.RDD

object ejemplo {
  def main( args: Array[String]):Unit={
    val conf = new SparkConf().setAppName("primera").setMaster("local[*]")

    val sc = new SparkContext(conf)

    val array = Array(23,54,32,66,0,-14,-8,10)
    val numerosRDD = sc.parallelize(array,3)

    //println("El valor máximo dentro de numerosRDD es " + numerosRDD.max() + " y el mínimo
" + numerosRDD.min())
    println("La suma de todos los elementos es: " + numerosRDD.reduce((x,y) => x+y))
  }
}
```

El valor máximo dentro de numerosRDD es 66 y el mínimo -14

La suma de todos los elementos es: 163

EJERCICIO 2

Realiza un filtrado del RDD anterior quedándonos únicamente con las palabras de tamaño 6 o superior. Luego, transforma esas palabras a mayúsculas

```
import org.apache.spark.SparkConf
import org.apache.spark.SparkContext
import org.apache.spark.rdd.RDD

object ejemplo {

  def main( args: Array[String]):Unit={

    val conf = new SparkConf().setAppName("primera").setMaster("local[*]")
```

```
val sc = new SparkContext(conf)
```

```
//carga del fichero loremipsum.txt
```

```
val lorem = sc.textFile("lectura.txt")
```

```
val mayor6 = lorem.flatMap(line => line.split(" ")).filter(p => p.length() >= 6)
```

```
val maymayor6 = mayor6.map(x => x.toUpperCase())
```

```
val lista=maymayor6.collect().foreach(println)
```

```
}
```

Ejercicio3 Dada una lista de animales ("Perro","Gato","Tigre","Caballo","Camello","Perro") debemos mostrar de todos ellos los que no sean de una categoría concretar (en este caso queremos eliminar de la lista al "Perro")

```
import org.apache.spark.SparkConf
```

```
import org.apache.spark.SparkContext
```

```
import org.apache.spark.rdd.RDD
```

```
object ejemplo {
```

```
def main( args: Array[String]):Unit={
```

```
    val conf = new SparkConf().setAppName("primera").setMaster("local[*]")
```

```
    val sc= new SparkContext(conf)
```

```
    val listaAnimales = List("Perro","Gato","Tigre","Caballo","Camello","Perro")
```

```
    //todas las transformaciones de un RDD son lazy
```

```
    val animalesRDD = sc.parallelize(listaAnimales)
```

```
    val animalesSinRepeticionesSinPerros = animalesRDD.distinct().filter(animal => animal != "Perro").collect()
```

```
    for(animal <- animalesSinRepeticionesSinPerros) {
```

```
        println(animal)
```

```
    }
```

```
    sc.stop() }}
```

EJERCICIO3

EJERCICIO1. Se nos facilita una lista formada por pares K-V como la siguiente:

Lista=(("11111111H",39.1),("22222222H",34.2),("11111111H",39.6),("33333333H",37.4),("22222222H",36.5)) .

Queremos que nuestro código nos muestre por cada cliente de mi lista la cantidad de dinero que se gastado en las compras de navidad.

Debemos resolverlo usando GROUPBYKEY y después REDUCEBYKEY

```
import org.apache.spark.SparkConf
```

```
import org.apache.spark.SparkContext
```

```
import org.apache.spark.rdd.RDD
```

```
object ejemplo {
```

```
  def main( args: Array[String]):Unit={
```

```
    val conf = new SparkConf().setAppName("primera").setMaster("local[*]")
```

```
    val sc= new SparkContext(conf)
```

```
    val cliente =
```

```
List(("11111111H",39.1),("22222222H",34.2),("11111111H",39.6),("33333333H",37.4),("22222222H",36.5))
```

```
    val clienteRDD = sc.parallelize(cliente) //RDD
```

```
    //GROUPBYKEY
```

```
    /*
```

```
    ("11111111H",[39.1,39.6]) -> ("11111111H",(39.1+39.6))
```

```
    ("22222222H",[34.2,36.5])
```

```
    ("33333333H",[37.4])
```

```
    */
```

```
    val valores = clienteRDD.groupByKey()
```

```
    .map(cliente=> (cliente._1,cliente._2.sum))
```

```
    valores.foreach(println)
```

```
//REDUCEKEY

val valoresReduce = clienteRDD.reduceByKey((a,b) => a + b).collect()

valoresReduce.foreach(println)

sc.stop() }}
```

EJERCICIO 5

Haciendo uso del fichero “LorenIpsum.txt”, carga su contenido en un RDD. Luego, implementa **un cuenta palabras**. Mostrar por cada clave su valor

```
//importamos SparkConf, SparkContext, RDD
import org.apache.spark.SparkConf
import org.apache.spark.SparkContext
import org.apache.spark.rdd.RDD

object ejemplo {
  def main( args: Array[String]):Unit={
    val conf = new SparkConf().setAppName("primera").setMaster("local[*]")
    val sc = new SparkContext(conf)
    //carga del fichero loremipsum.txt
    val lorem = sc.textFile("lectura.txt")
    //dividir por palabras
    val palabras = lorem.flatMap(line => line.split(" "))
    //map para contar crear el par clave-valor para cada palabra
    .map(word => (word,1))
    //numero de ocurrencias por cada clave
    .reduceByKey(_+_ )
    print(palabras.collectAsMap())

  }
```

EJERCICIO 6 LEER EL COTENIDO DE UN FICHERO

```
import org.apache.spark.SparkConf
import org.apache.spark.SparkContext

import org.apache.spark.sql.Dataset
import org.apache.spark.sql.DataFrame
import org.apache.spark.sql.SparkSession

object ejemplo {
  def main(args: Array[String]): Unit = {
    al spark:SparkSession = SparkSession.builder()
      .master("local[*]")
      .appName("lectura TXT ")
      .getOrCreate()

    spark.sparkContext.setLogLevel("ERROR")  val rdd3 =
    spark.sparkContext.textFile("lectura.txt")

    rdd3.foreach(println)
```

EJERCICIO7 LEER LOS FICHEROS QUE CUMPLAN ESE PATRON CON * ¿ ETC...

```
import org.apache.spark.SparkConf
import org.apache.spark.SparkContext

import org.apache.spark.sql.Dataset
import org.apache.spark.sql.DataFrame
import org.apache.spark.sql.SparkSession

object ejemplo {
```

```
def main(args: Array[String]): Unit = {  
  al spark:SparkSession = SparkSession.builder()  
    .master("local[*]")  
    .appName("lectura TXT CON PATRON ")  
    .getOrCreate()  
  
  spark.sparkContext.setLogLevel("ERROR")  
  val rdd3 = spark.sparkContext.textFile("lec*.txt")  
  rdd3.foreach(println)
```